

# 基于高频特征的短期价格预测策略研究

张子乐, 3230104237

量化投资作业 2

2026 年 2 月 9 日

## 摘要

本研究旨在利用高频快照数据，构建机器学习模型以预测未来 15 秒左右的价格变动趋势。通过构建订单流累加值、买卖双方挂单量及价格相对 VWAP 位置等特征，以中间价的变动方向为预测目标，使用 XGBoost 模型实现了 F1-Score 0.55 和 AUC 0.74 的预测性能。研究发现，尽管模型具备较强的方向预测能力，但在考虑真实买卖价差和交易成本后，普通策略无法盈利。通过引入阈值过滤噪音交易，本研究最终构建了一个在扣除双边万二手续费后依然能够稳定盈利的高盈亏比策略。

## 目录

|       |            |    |
|-------|------------|----|
| 1     | 引言         | 2  |
| 2     | 机器学习模型     | 2  |
| 2.1   | 逻辑斯蒂回归     | 2  |
| 2.2   | 支持向量机      | 2  |
| 2.3   | XGBoost    | 3  |
| 2.4   | LightGBM   | 3  |
| 3     | 数据准备与特征提取  | 3  |
| 3.1   | 数据准备       | 3  |
| 3.2   | 特征工程       | 4  |
| 3.2.1 | 盘口形态与价差特征  | 4  |
| 3.2.2 | 订单流        | 6  |
| 3.2.3 | 价格动态与波动率   | 7  |
| 3.2.4 | 交易强度与流动性特征 | 8  |
| 3.2.5 | 微观技术指标     | 8  |
| 3.2.6 | 原始数据特征及其衍生 | 10 |
| 3.3   | 特征重要性      | 10 |

|                  |           |
|------------------|-----------|
| 目录               | 2         |
| <b>4 实验过程与结果</b> | <b>12</b> |
| 4.1 预测目标         | 12        |
| 4.2 机器学习模型的评价指标  | 13        |
| 4.3 贝叶斯优化        | 13        |
| 4.4 模型训练与评估      | 14        |
| <b>5 回测</b>      | <b>16</b> |
| 5.1 回测逻辑         | 18        |
| 5.2 5 折时间序列交叉验证  | 18        |
| 5.3 冷却机制         | 18        |
| 5.4 回测结果         | 19        |
| <b>6 结论</b>      | <b>21</b> |

## 1 引言

近年来，高频交易在证券市场的成交占比显著提升，高频交易已成为金融市场流动性的重要提供者，这迫切要求交易策略具备极短时间窗口内的价格预判能力。然而，针对高频数据信噪比极低这一核心难点，传统计量经济学模型往往难以捕捉其中复杂的非线性模式。

相比之下，机器学习方法引入了更为系统的数据表征机制，通过从历史数据中学习潜在规律并进行泛化，显著提升了模型对样本外数据的分类与预测精度。随着 GPU 并行计算能力的突破及海量微观数据的积累，机器学习模型已成为量化投资领域的前沿工具。

本研究基于 002507 股票的高频快照数据，通过特征工程构建了 50 个刻画市场微观状态的有效特征，并训练机器学习模型对未来 15 秒的中间价变化进行预测。实验表明，根据机器学习模型预测的结果，辅以合理的交易策略与风险控制，能够在真实市场环境下实现稳健的超额收益。

## 2 机器学习模型

本研究选取了四种经典的机器学习算法进行对比实验，涵盖了线性模型和集成学习模型。这些模型在金融时间序列预测中均有广泛应用。

### 2.1 逻辑斯蒂回归

逻辑斯蒂回归是一种广义线性模型，在实际应用中主要用于处理二分类问题。其核心思想是通过 Sigmoid 函数将线性回归模型的输出映射到  $(0, 1)$  区间，从而将连续值转化为概率值。

假设输入特征向量为  $x \in \mathbb{R}^n$ ，权重向量为  $w$ ，偏置为  $b$ ，则逻辑斯蒂回归的预测模型可表示为：

$$P(y = 1|x) = \sigma(w^T x + b) = \frac{1}{1 + e^{-(w^T x + b)}} \quad (1)$$

模型通过最大化对数似然函数来估计参数，结构较为简单。

### 2.2 支持向量机

支持向量机的核心目标是寻找一个最优超平面，其在特征空间中能将不同类别的样本分开，且使得两类样本到超平面的间隔最大。

对于线性不可分的数据，SVM 通过引入核函数  $K(x_i, x_j)$  将低维空间的非线性问题映射到高维空间，使其转化为线性可分问题。其优化目标可以表示为：

$$\min_{w, b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \quad (2)$$

其中  $\xi_i$  为松弛变量,  $C$  为惩罚系数。

本次实验调用 scikit-learn 库中的 LinearSVC 模型是支持向量机在线性可分或近似线性可分场景下的高效实现形式, 其显式地在原始特征空间中求解线性分类器, 不依赖核函数映射, 因而计算复杂度显著降低, 特别适用于高维稀疏数据。

## 2.3 XGBoost

XGBoost 是对 GBDT 算法的一种高效实现。作为一个集成学习模型, 它串行训练多棵决策树, 每棵新树拟合前一轮模型的预测残差, 最终将所有树的预测值累加得到结果。

相比传统 GBDT, XGBoost 在目标函数中引入了正则化项以控制模型复杂度, 防止过拟合。其目标函数由损失函数  $L$  和正则化项  $\Omega$  组成, 并在优化过程中利用了二阶泰勒展开:

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^n [l(y_i, \hat{y}_i^{(t-1)}) + g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i)] + \Omega(f_t) \quad (3)$$

其中  $g_i$  和  $h_i$  分别为损失函数的一阶和二阶导数。

此外, XGBoost 支持列抽样和缺失值自动处理, 在 Kaggle 各项数据挖掘竞赛中表现卓越。

## 2.4 LightGBM

LightGBM 是另一种高效的 GBDT 实现框架, 旨在解决海量数据下的训练效率和内存消耗问题。相比 XGBoost, LightGBM 在处理高维、大规模数据时具有更快的训练速度和更低的内存占用。

LightGBM 的核心创新主要体现在以下三个方面: 第一, 它将连续的浮点特征离散化为  $k$  个离散值, 并构造直方图, 大幅降低了内存消耗和分裂点计算的时间复杂度; 第二, 它采用单边梯度采样的 Goss 算法, 保留大梯度样本, 随机采样小梯度样本, 在减少数据量的同时保证了信息增益的准确性; 第三, 它将互斥的稀疏特征捆绑为一个特征, 降低了特征维度。此外, LightGBM 还采用了带有深度限制的 Leaf-wise 叶子生长策略, 相比传统的 Level-wise 策略, 能更高效地降低模型损失。

# 3 数据准备与特征提取

## 3.1 数据准备

本研究选取了 002507 股票作为研究对象。数据样本的时间跨度为 2016 年 1 月 4 日至 2019 年 12 月 31 日, 覆盖了完整的 4 个交易年度。所使用的数据类型为 Level-2 高频快照数据, 不同于传统的 Level-1 数据仅包含五档行情, Level-2 数据提供了更为丰

富和微观的市场深度信息，能够精确捕捉市场的瞬时供需状态，为机器学习的特征工程打下了坚实的基础。

原始数据包含详细的时间戳、成交信息以及十档盘口行情，大致可以分为三个大类：基础交易数据包括时间戳、最新成交价、开盘价、最高价、最低价、成交量等，盘口深度数据包括卖一至卖十申报价和申报量、买一至买十申报价和申报量等 10 档买卖挂单信息，统计指标包括卖方和买方委托总量、卖方和买方加权平均价等。

## 3.2 特征工程

特征工程是机器学习中最重要的一部分，为了捕捉微观市场的动态，本研究构建了以下特征，分类如表1所示：

### 3.2.1 盘口形态与价差特征

**价差：**spread\_i, rel\_spread\_i, ask\_diff\_i\_j, bid\_diff\_i\_j：价差是衡量市场流动性最直接的指标，反映了交易的显性成本。为了消除股价绝对值波动的影响，本研究同时构建了绝对价差与相对价差。

设  $P_{i,t}^a$  和  $P_{i,t}^b$  分别为  $t$  时刻第  $i$  档 ( $i \in [1, 10]$ ) 的卖价与买价，则第  $i$  档的绝对价差  $S_{i,t}$  定义为：

$$S_{i,t} = P_{i,t}^a - P_{i,t}^b \quad (4)$$

进一步地，为了标准化不同价格区间的流动性指标，我们定义第  $i$  档的相对价差  $RS_{i,t}$ ：

$$RS_{i,t} = \frac{P_{i,t}^a - P_{i,t}^b}{(P_{i,t}^a + P_{i,t}^b)/2} \quad (5)$$

其中分母为该档位的中间价。价差越窄，表明市场流动性越好，买卖双方的撮合意愿越强烈。

**盘口斜率：**ask/bid\_slope, slope\_diff：盘口斜率特征将离散的挂单数据抽象为几何曲线，用于衡量单位价格变动所需的成交量深度。斜率越大，意味着单位价格区间内的挂单量越少，价格越容易被大单击穿；反之则代表存在较强的支撑或阻力。

我们将卖方盘口斜率  $Slope_t^a$  定义为卖十价与卖一价之差与总挂单量之比：

$$Slope_t^a = \frac{P_{10,t}^a - P_{1,t}^a}{\sum_{k=1}^{10} V_{k,t}^a} \quad (6)$$

同理可得买方盘口斜率  $Slope_t^b$ 。此外，我们引入斜率差  $Slope\_Diff_t = Slope_t^a - Slope_t^b$  来捕捉买卖双方防御强度的非对称性。

**深度结构与集中度：**depth\_ratio\_w, ask/bid\_conc\_L1：为了刻画挂单量的分布结构，我们构建了深度比率与头部集中度特征。

表 1: 特征分类

| 特征类别     | 特征名                                                                                                                                                | 特征描述                                                                   |
|----------|----------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------|
| 盘口形态与价差  | spread_i, rel_spread_i,<br>ask_diff_i_j, bid_diff_i_j,<br>bid_price_range_1_10,<br>ask/bid_slope, slope_diff,<br>ask/bid_conc_L1,<br>depth_ratio_w | 涵盖多档买卖价差、相对价差；<br>盘口斜率反映挂单的陡峭程度；集中度反映头部挂单的占比；深度比率衡量买卖盘的厚度差异。           |
| 订单流      | vol_imbalance_i,<br>mean_imbalance_w,<br>OFI_sum_w, OFI_acc_w,<br>raw_OFI,<br>flow_sum_w, flow_ratio_w                                             | vol_imbalance 衡量静态挂单量的差异；OFI 捕捉买卖压力的动态变化及其加速度；资金流特征衡量主动成交的方向性。         |
| 价格动态与波动率 | ret_w, std_w, std_ratio_w,<br>ret_skew_w, ret_kurt_w,<br>micro_price_dev, deriv_col,<br>price_rel_vwap_w                                           | 收益率分布的高阶矩：偏度和峰度；微观价格相对于中间价的偏离度；各阶导数反映价格和成交量的变化速度；相对波动率衡量当前波动状态。        |
| 交易强度与流动性 | lambda_market, lambda_flow,<br>accel_lambda, amihud_illiq,<br>amihud_mean_w                                                                        | Lambda 系列特征基于 Hawkes 过程思想，衡量市场到达率和交易活跃度；Amihud 指标衡量单位成交量带来的价格冲击（非流动性）。 |
| 技术指标     | RSI_14t, MACD, MACD_hist,<br>MFI_w, bb_pos_w,<br>ma_bias_w, pos_in_range_w                                                                         | 经典技术指标的微观化应用：相对强弱指标、平滑异同移动平均线、资金流量指标、布林带位置及均线乖离率，用于捕捉趋势和超买超卖信号。        |
| 原始数据特征   | ask_volume_i, bid_volume_i,<br>ask_price_i, bid_price_i,<br>vol_diff                                                                               | 原始数据中的十档买卖价和买卖量特征，vol_diff 反映买卖盘总挂单量的差异。                               |

注：w 代表时间窗口 (20, 60, 100 ticks), i 代表盘口档位 (1 ~ 10)。

深度比率衡量了买卖双方在一定时间窗口  $w$  内的总挂单意愿差异。该指标通过滑动窗口平滑了瞬时撤单带来的噪音：

$$DR_{w,t} = \frac{\sum_{\tau=t-w+1}^t \sum_{k=1}^{10} V_{k,\tau}^b}{\sum_{\tau=t-w+1}^t \sum_{k=1}^{10} V_{k,\tau}^a} \quad (7)$$

当  $DR_{w,t} > 1$  时，表明买盘挂单厚度大于卖盘，市场底部支撑较强。

头部集中度特征量化了最优报价档位的挂单量在十档总挂单中的占比。以卖方为例：

$$Conc_{L1,t}^a = \frac{V_{1,t}^a}{\sum_{k=1}^{10} V_{k,t}^a} \quad (8)$$

极高的头部集中度通常意味着市场参与者急于在当前价格成交，往往预示着短期价格的剧烈波动。

### 3.2.2 订单流

不同于静态的盘口形态，订单流特征旨在捕捉买卖压力的动态演变，是预测短期价格变动的核心。

**静态挂单差异：vol\_imbalance\_i, mean\_imbalance\_w**：静态不平衡衡量了当前时刻买卖盘挂单量的差异。我们计算前  $i$  档 ( $i \in \{1, 5, 10\}$ ) 的累计挂单不平衡度  $\rho_{i,t}$ ：

$$\rho_{i,t} = \frac{\sum_{k=1}^i V_{k,t}^b - \sum_{k=1}^i V_{k,t}^a}{\sum_{k=1}^i V_{k,t}^b + \sum_{k=1}^i V_{k,t}^a} \quad (9)$$

其中  $\rho_{i,t} \in [-1, 1]$ 。当  $\rho_{i,t} \rightarrow 1$  时，表明买盘挂单具有压倒性优势，价格面临上行压力。

**订单流不平衡：raw\_OFI, OFI\_sum\_w, OFI\_acc\_w**：OFI 指标通过整合价格变化与挂单量变化，量化了导致最佳报价变动的净买卖压力。

买单流  $e_t^b$  定义如下：

$$e_t^b = \begin{cases} V_{1,t}^b & \text{if } P_{1,t}^b > P_{1,t-1}^b \\ V_{1,t}^b - V_{1,t-1}^b & \text{if } P_{1,t}^b = P_{1,t-1}^b \\ -V_{1,t-1}^b & \text{if } P_{1,t}^b < P_{1,t-1}^b \end{cases} \quad (10)$$

同理可定义卖单流  $e_t^a$ 。

原始 OFI 定义为  $OFI_t = e_t^b - e_t^a$ 。为了消除噪音，我们进一步构建了 OFI 的累计值与加速度特征：

$$OFI_{sum,w} = \sum_{\tau=t-w+1}^t OFI_{\tau}, \quad OFI_{acc,w} = \Delta_5(OFI_{sum,w}) \quad (11)$$

**资金流特征：flow\_sum\_w, flow\_ratio\_w**：资金流特征旨在通过量价配合关系来捕捉市场的主力动向。其将每一笔成交赋予方向性，从而量化资金的净流入与流出强度。

为了判断成交的主动性方向,我们依据价格变动符号将成交额 Turnover 划分为流入或流出。设  $P_{mid,t}$  为  $t$  时刻中间价,  $Amt_t$  为该时刻的成交额,则单笔资金流  $F_t$  定义为:

$$F_t = \begin{cases} Amt_t & \text{if } \Delta P_{mid,t} > 0 \quad (\text{资金流入}) \\ -Amt_t & \text{if } \Delta P_{mid,t} < 0 \quad (\text{资金流出}) \\ 0 & \text{otherwise} \end{cases} \quad (12)$$

基于此,构建时间窗口  $w$  内的累计净资金流  $FlowSum_{w,t}$  和资金流比率  $FlowRatio_{w,t}$ :

$$FlowSum_{w,t} = \sum_{\tau=t-w+1}^t F_{\tau} \quad (13)$$

$$FlowRatio_{w,t} = \frac{FlowSum_{w,t}}{\sum_{\tau=t-w+1}^t Amt_{\tau} + \epsilon} \quad (14)$$

其中  $FlowRatio \in [-1, 1]$ 。该比率消除了成交额量级的影响,能够直观反映多空双方在资金投入上的相对强弱。

### 3.2.3 价格动态与波动率

**ret\_w, std\_w:** 中间价的收益率与标准差。

**微观价格与偏离度: micro\_price\_dev:** 由于买卖挂单量的差异,中间价往往不能真实反映价值。我们引入以挂单量加权的微观价格  $P_{micro,t}$ :

$$P_{micro,t} = \frac{P_{1,t}^a V_{1,t}^b + P_{1,t}^b V_{1,t}^a}{V_{1,t}^a + V_{1,t}^b} \quad (15)$$

该指标考虑了最佳档位的挂单厚度,往往比中间价先行一步。在此基础上,微观价格偏离度  $D_{micro,t} = P_{micro,t} - P_{mid,t}$  有效度量了短期价格的修正压力。

**高阶矩与相对波动率: ret\_skew\_w, ret\_kurt\_w, std\_ratio\_w:** 为了捕捉极端行情风险,本研究计算了收益率分布的偏度与峰度。此外,引入相对波动率指标  $R\sigma_{w,t}$  来衡量当前市场是否处于变盘节点:

$$R\sigma_{w,t} = \frac{\sigma_{w,t}}{\frac{1}{2w} \sum_{\tau=t-2w+1}^t \sigma_{w,\tau}} \quad (16)$$

该指标对比了短期波动率与长期平均波动率,数值突增通常预示着新趋势的形成。

**盘口导数: deriv\_col:** 设  $X_{k,t}$  为  $t$  时刻第  $k$  档的价格或挂单量(即  $X \in \{P^a, P^b, V^a, V^b\}$ ),  $\Delta t$  为当前快照与上一快照的时间间隔。则特征变量  $X$  的一阶导数  $D_{X,t}$  定义为:

$$D_{X,t} = \frac{X_{k,t} - X_{k,t-1}}{\Delta t} = \frac{\Delta X_{k,t}}{\Delta t} \quad (17)$$

当  $X$  为价格时,  $D_{P,t}$  衡量了报价的上跳或下行速度。高绝对值意味着市场正在经历剧烈的重新定价过程。当  $X$  为挂单量时,  $D_{V,t}$  近似衡量了该档位的净挂单/撤单速率。若  $D_{V,t} \ll 0$ , 通常捕捉到的是流动性的快速抽离,往往是价格崩塌的前兆。



**相对 VWAP 位置: price\_rel\_vwap\_w:**

成交量加权平均价 (VWAP) 是日内高频交易中衡量市场平均持仓成本的关键基准。该特征旨在量化当前市场价格相对于短期平均成交成本的偏离程度, 从而判断多空双方的获利状态与趋势强度。

首先, 定义时间窗口  $w$  内的滚动 VWAP 为累计成交额与累计成交量之比:

$$VWAP_{w,t} = \frac{\sum_{\tau=t-w+1}^t (P_{\tau} \cdot V_{\tau})}{\sum_{\tau=t-w+1}^t V_{\tau}} \quad (18)$$

基于此, 构建价格相对 VWAP 的偏离度特征  $D_{VWAP,w,t}$ :

$$D_{VWAP,w,t} = \frac{P_{mid,t}}{VWAP_{w,t}} - 1 \quad (19)$$

当  $D_{VWAP} > 0$  时, 表明当前价格运行于平均成本之上, 近期入场的资金处于浮盈状态, 市场处于多头主导的趋势中, VWAP 往往构成有效支撑。当  $D_{VWAP} < 0$  时, 表明当前价格低于平均成本, 近期买盘处于浮亏状态, 上方存在解套抛压, VWAP 转化为阻力位。而极端高绝对值的  $D_{VWAP}$  通常预示着价格对于成本线的过度偏离, 可能引发均值回归行情。

**3.2.4 交易强度与流动性特征**

**市场交易强度: lambda\_market, lambda\_flow:** 基于点过程理论, 我们将成交量的到达率定义为交易强度  $\lambda_t$ 。为了处理非等间隔的时间序列, 我们利用快照的时间间隔  $\Delta t$  对成交量进行归一化:

$$\lambda_{market,t} = \frac{Volume_t}{\Delta t}, \quad \lambda_{flow,t} = \frac{\Delta V_{total,t}}{\Delta t} \quad (20)$$

其中  $\lambda_{market}$  反映了成交的活跃程度, 而  $\lambda_{flow}$  反映了挂单流的到达速度。

**非流动性指标: amihud\_illiq, amihud\_mean\_w:** 该指标衡量了单位成交金额引起的价格波动幅度, 反映了市场的价格冲击成本:

$$ILLIQ_{w,t} = \frac{1}{w} \sum_{\tau=t-w+1}^t \frac{|R_{\tau}|}{Turnover_{\tau}} \quad (21)$$

ILLIQ 值越高, 表明市场深度越浅, 大额交易越容易造成价格滑点。

**3.2.5 微观技术指标**

我们将经典技术指标适配于高频数据, 以捕捉日内趋势与反转信号。

**平滑异同移动平均: MACD, MACD\_hist:** MACD 利用不同周期的指数移动平均线 EMA 的聚合与分离, 来判断价格动量的变化。对于高频率序列  $P_{mid}$ :

$$\begin{aligned} DIF_t &= EMA(P_{mid}, 12) - EMA(P_{mid}, 26) \\ DEA_t &= EMA(DIF, 9) \\ MACD\_Hist_t &= DIF_t - DEA_t \end{aligned} \quad (22)$$

其中  $DIF$  反映了短期价格相对于长期价格的偏离速度,  $MACD\_Hist$  代表了动量的加速度。当  $Hist > 0$  且扩大时, 表明上涨动能正在加速。

**相对强弱指标: RSI\_14t:** RSI 衡量了特定窗口内价格上涨幅度与下跌幅度的相对强弱, 用于识别微观层面的超买或超卖状态。设  $\Delta P_t = P_{mid,t} - P_{mid,t-1}$ , 定义上涨动能  $U_t$  和下跌动能  $D_t$ :

$$U_t = \max(\Delta P_t, 0), \quad D_t = |\min(\Delta P_t, 0)| \quad (23)$$

计算平滑后的相对强度  $RS_t$  及最终指标:

$$RS_t = \frac{EMA(U, 14)}{EMA(D, 14)}, \quad RSI_t = 100 - \frac{100}{1 + RS_t} \quad (24)$$

在高频数据下, 极端的高 RSI ( $> 80$ ) 往往不代表趋势延续, 而是意味着买盘耗尽, 短期内价格回调的概率增大。

**布林带相对位置: bb\_pos\_w:** 布林带是一种波动率通道类技术指标, 通常由中间的移动平均线和上下两条标准差通道组成。该特征衡量当前价格相对于布林带的位置。代码中的计算公式为:

$$BB\_Pos_{w,t} = \frac{P_{mid,t} - (MA_{w,t} - 2\sigma_{w,t})}{4\sigma_{w,t}} \quad (25)$$

其中分母  $4\sigma_{w,t}$  代表布林带的总宽度。 $BB\_Pos \approx 0$ , 代表价格触及下轨;  $BB\_Pos \approx 0.5$ , 代表价格位于均线附近;  $BB\_Pos \approx 1$ , 则代表价格触及上轨。因此该特征有效捕捉了价格相对于当前波动率环境的偏离程度。

**极值区间位置: pos\_in\_range\_w:** 该特征类似于随机指标中的  $\%K$  线, 衡量当前价格在过去  $w$  窗口内的最高价与最低价之间的相对位置:

$$Pos\_Range_{w,t} = \frac{P_{mid,t} - \min(P_{t-w:t})}{\max(P_{t-w:t}) - \min(P_{t-w:t})} \quad (26)$$

当  $Pos \rightarrow 1$  时, 表明价格收于近期高点, 买方完全主导了该时间窗口, 具备突破潜力; 当  $Pos \rightarrow 0$  时, 表明价格被压制在近期低点, 卖方力量占优。相比于  $BB\_Pos$ , 该特征对极值点更敏感, 适合捕捉箱体震荡中的反转信号。

**价格相对 VWAP 位置: price\_rel\_vwap\_w:** 该特征反映了当前价格相对于机构平均持仓成本的位置, 是判断多空力量对比的重要基准。

$$Pos_{VWAP,w} = \frac{P_{mid,t}}{VWAP_{w,t}} - 1 \quad (27)$$

其中  $VWAP_{w,t}$  为过去  $w$  个时间步的成交量加权平均价。

**MF1\_i:** 传统的资金流量指标 MF1 常用于日线级别, 这里将其改良适配至高频数据。首先定义微观典型价格  $TP_t$ :

$$TP_t = \frac{P_{ask,1,t} + P_{bid,1,t} + P_{mid,t}}{3} \quad (28)$$

原始资金流定义为  $RMF_t = TP_t \times Vol_t$ 。依据典型价格的变化方向, 将  $RMF$  分解为正向流  $PMF$  和负向流  $NMF$ :

$$\begin{aligned} PMF_w &= \sum_{\tau=t-w+1}^t RMF_{\tau} \cdot \mathbb{I}(TP_{\tau} > TP_{\tau-1}) \\ NMF_w &= \sum_{\tau=t-w+1}^t RMF_{\tau} \cdot \mathbb{I}(TP_{\tau} < TP_{\tau-1}) \end{aligned} \quad (29)$$

最终计算  $w$  窗口内的 MFI 指标, 用于识别超买 ( $> 80$ ) 或超卖 ( $< 20$ ) 状态:

$$MFI_{w,t} = 100 - \frac{100}{1 + \frac{PMF_w}{NMF_w + \epsilon}} \quad (30)$$

### 3.2.6 原始数据特征及其衍生

这部分特征直接来源于原始数据, 部分根据论文《Modeling high frequency limit order book dynamics with support vector machines》构建:

**ask\_volume\_i, bid\_volume\_i:** 十档买卖挂单量

**ask\_price\_i, bid\_price\_i:** 十档买卖报价

**vol\_diff:** 总买卖挂单量差

由于高频数据可能存在缺失值、异常值, 在构建特征前后对数据进行了清洗, 对超出平均值三倍标准差的异常值进行了截断, 对部分缺失值进行了时间序列上的前向填充, 部分缺失值直接丢弃。同时剔除了集合竞价阶段的数据, 仅保留了 09:30:00 - 11:30:00 和 13:00:00 - 14:57:00 这两个时间段的数据。此外, 前后两条数据时间间隔的中位数约为 3 秒, 由于研究目标为高频 (15 秒 60 秒) 的价格预测, 对于时间间隔超过 90s 的数据点, 也将其剔除以保证数据的连续性。

## 3.3 特征重要性

本研究采用 LightGBM 模型默认的分裂频次作为衡量特征重要性的核心指标。该指标量化了每个特征在构建集成决策树过程中被模型选中并用于划分数据的频率。

在 GBDT 框架下, 特征  $f$  的分裂重要性  $I_{split}(f)$  定义为该特征在所有决策树的所有节点中被选作分裂特征的总次数。

假设模型由  $T$  棵决策树组成, 每棵树包含  $J$  个非叶节点。记  $v_{t,j}$  为第  $t$  棵树中第  $j$  个节点所使用的最佳分裂特征, 则特征  $f$  的重要性计算如下:

$$I_{split}(f) = \sum_{t=1}^T \sum_{j=1}^J \mathbb{I}(v_{t,j} = f) \quad (31)$$

其中  $\mathbb{I}(\cdot)$  为指示函数, 当条件满足时取 1, 否则取 0。

如果一个特征的 Split 值很高, 说明模型在为了区分不同样本时, 倾向于频繁地咨询该特征。这通常意味着该特征包含高密度的有效信息, 或者在不同的决策边界上都具

有鲁棒的区分能力。通过对 Split 重要性进行降序排列，能够识别出那些在整个预测过程中被模型反复使用的特征。

值得注意的是，在给特征重要性排序时，需要为 LightGBM 模型的正则化参数设置较高的值。这是因为正则化参数直接决定了叶子节点的最佳权重  $w^*$  和分裂增益  $Gain$ 。以  $L_2$  正则化为例，叶子权重的计算公式为：

$$w^* = -\frac{\sum g_i}{\sum h_i + \lambda} \quad (32)$$

当调大  $\lambda$  时，分母增大，导致叶子权重  $w^*$  被压缩，进而使得该次分裂计算出的结构分数降低。这促使模型在选择分裂特征时，更加倾向于选择那些能够带来显著增益的特征，从而提升特征重要性的区分度。




图 1: 特征重要性排名

根据 LightGBM 模型的运行结果，图 1 展示了前 50 个最重要的特征。其中订单流累加值 (OFI\_sum\_20)、卖方挂单量 (ask\_volume\_1)、价格相对 VWAP 位置 (price\_rel\_vwap\_20) 和买方挂单量 (bid\_volume\_1) 等特征在模型中占据了较为显著的位置。

接下来将使用特征重要性排名前 50 的特征进行后续的模型训练与评估，以期提升模型的预测性能与泛化能力。

## 4 实验过程与结果

### 4.1 预测目标

在高频交易场景中，资产价格受噪音影响显著。为了提取具有持续性的价格趋势信号，本研究并未采用容易受买卖价差跳动影响的最新成交价，而是基于中间价构建预测目标。

中间价被定义为当前时刻最优卖出价与最优买入价的算术平均值。设  $t$  时刻的卖一价为  $P_t^{ask}$ ，买一价为  $P_t^{bid}$ ，则中间价  $P_{mid,t}$  定义为：

$$P_{mid,t} = \frac{1}{2}(P_t^{ask} + P_t^{bid}) \quad (33)$$

中间价的变动反映了供需状态的转移：其向上移动意味着买方力量增强导致卖一档被吃掉，或卖方撤单导致卖一价上移，此时市场的公允价值估值上调；其向下移动则意味着卖方力量增强击穿买一档，或买方流动性撤离，此时市场的公允价值估值下调。

相比于最新成交价，中间价能够天然过滤掉因主动买入或主动卖出导致的在 Bid 和 Ask 之间反复跳跃的高频噪音，从而更准确地表征资产的潜在价值趋势。

尽管中间价剔除了价差噪音，但单点时刻的中间价仍可能包含随机扰动。为了获得稳健的趋势标签，本研究并未直接使用未来第  $H$  个 tick 的单点价格，而是计算未来  $H$  个时间步内中间价的均值。设预测视野为  $H$ （本实验中  $H = 5$ ，约对应 15 秒），则  $t$  时刻对应的未来平滑价格  $\bar{P}_{t,H}$  定义为：

$$\bar{P}_{t,H} = \frac{1}{H} \sum_{i=1}^H P_{mid,t+i} \quad (34)$$

该处理方式相当于在时间序列上对未来价格序列施加了一个低通滤波器，有效平滑了瞬时的价格起伏，使模型聚焦于持续性的价格移动。

基于平滑后的未来价格，我们定义  $t$  时刻的预期收益率  $r_t$ ：

$$r_t = \frac{\bar{P}_{t,H}}{P_{mid,t}} - 1 \quad (35)$$

为了将连续回归问题转化为离散分类问题，我们引入阈值  $\tau$ （本实验设为 0.00008），采用三分类法构建分类标签  $Y_t$ ：

$$Y_t = \begin{cases} +1 & (\text{Up}) & \text{if } r_t > \tau \\ -1 & (\text{Down}) & \text{if } r_t < -\tau \\ 0 & (\text{Stationary}) & \text{otherwise} \end{cases} \quad (36)$$

其中，类别 +1 代表显著上涨趋势，-1 代表显著下跌趋势，0 代表价格在阈值范围内震荡或趋势不明显。

正如数据预处理部分所述，高频快照数据在时间上并非绝对连续，存在如午休、隔夜或临时停牌等时间断点。跨越这些断点的收益率计算会导致标签失真。因此，我们构

建了有效性掩码，剔除所有  $Time(t+H) - Time(t) > 90s$  的样本，确保每个训练样本的标签均基于连续的市场微观结构。

## 4.2 机器学习模型的评价指标

为了全面评估机器学习模型在样本外数据上的预测性能，本研究采用四个评价指标：准确率 (Accuracy)、召回率 (Recall)、F1 分数 (F1-Score) 以及 ROC 曲线下面积 (AUC)。

在定义这些指标之前，基于预测类别与真实类别的匹配情况，我们将样本划分为：真阳性 (TP)、真阴性 (TN)、假阳性 (FP) 和假阴性 (FN)。

准确率是最直观的评估指标，衡量了模型在所有样本中做出正确分类的比例。其计算公式为：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (37)$$

召回率衡量了模型从所有真实的阳性样本中成功识别出阳性样本的能力。

$$Recall = \frac{TP}{TP + FN} \quad (38)$$

单一的精确率 ( $P = TP/(TP + FP)$ ) 或召回率往往无法全面评价模型。为了平衡查准率与查全率，引入 F1-Score，它是精确率与召回率的调和平均数。F1-Score 对类别不平衡数据更为敏感，能更好地反映模型的稳健性：

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (39)$$

该指标越高，表明模型在保证预测准确性的同时，也尽可能少地遗漏真实的市场机会。

AUC 指的是 ROC 曲线下的面积，表示随机抽取一个正样本和一个负样本，分类器将正样本排在负样本前面的概率。对于依赖阈值判定开仓的高频策略，AUC 是衡量模型排序能力的关键指标。AUC 越高，说明无论阈值如何设定，模型区分“涨跌”与“非涨跌”的能力越强，表明其预测分数具有更好的鲁棒性。

## 4.3 贝叶斯优化

在训练机器学习模型的过程中，调整模型的超参数是提升预测性能的关键步骤。为了最大化模型的预测性能，本研究调用了基于贝叶斯优化算法的 Optuna 库，自动寻找 LightGBM 和 XGBoost 等模型的最优超参数。相比于穷举式的网格搜索，贝叶斯优化适用于计算代价高昂的黑盒函数优化问题，能够在较少的迭代次数内收敛至全局最优解。

贝叶斯优化的核心思想是利用先验知识逼近目标函数  $f(x)$  的后验分布，其迭代过程包含两个关键组件：

1. 采用高斯过程作为概率代理模型，用于拟合目标函数并量化预测的不确定性，即均值  $\mu(x)$  与方差  $\sigma^2(x)$ 。

2. 构造一个效用函数，如期望增益来指导采样。该函数权衡了在已知高值区域搜索与在未采样的高不确定性区域搜索，从而选择下一个超参数组合：

$$x_{t+1} = \arg \max_x EI(x|\mathcal{D}_t) \quad (40)$$

其中  $\mathcal{D}_t$  为当前已有的观测数据集。

本次实验中取 F1-Score 作为优化目标，XGBoost 模型的贝叶斯优化过程如图2所示。




图 2: XGBoost 贝叶斯优化过程


#### 4.4 模型训练与评估

本次实验以 8:2 的比例在时间序列上划分训练集和测试集，避免出现未来信息泄露的情况。

首先使用 XGBoost 模型对预测目标的不同时间跨度  $H$  (5、10、20 个时间步，分别对应约 15 秒、30 秒和 60 秒)，取不同的阈值进行三分类做了对比评估。在不同时间跨度  $H$  下样本的分布如图3所示：

不同时间跨度  $H$  下 XGBoost 模型在测试集上的评估指标如表 2 所示。随着预测时间跨度的增加，模型的各项指标均有所下降。针对这一现象，我认为主要归因于以下两个市场机制：

一方面，本研究构建的特征（如 OFI、盘口斜率等）主要捕捉的是 Order Book 中瞬时的供需失衡状态，这类微观结构信号具有极高的时效性，通常只能解释极短时间内

图 3: 不同时间跨度  $H$  下样本的分布表 2: 不同时间跨度  $H$  下 XGBoost 模型在测试集上的评估指标

| 时间跨度 $H$ | 准确率 (Accuracy) | 召回率 (Recall) | F1-Score | AUC    |
|----------|----------------|--------------|----------|--------|
| 5(15s)   | 0.5576         | 0.5536       | 0.5542   | 0.7441 |
| 10(30s)  | 0.5483         | 0.5064       | 0.5127   | 0.7149 |
| 20(60s)  | 0.5310         | 0.4797       | 0.4847   | 0.6913 |

的价格变动过程。随着预测视野从 15s 延长至 60s, 当前 Order Book 的状态与未来价格之间的因果性减弱, 特征的预测效力随时间衰减。

另一方面, 在高频时间尺度下, 价格变化可以被视为由确定性微观趋势与随机布朗运动叠加的过程。随着时间步  $H$  的增加, 外生随机事件如新订单到达、撤单、突发交易等的影响不断累积, 导致市场系统中的信噪比大幅降低, 从而增加了模型的分类难度。

综上所述, 基于 Order Book 快照的特征在极短时间下表现最佳, 说明此类策略更适用于捕捉极短期的套利机会。

基于此, 选择  $H = 5$  作为后续实验的预测目标时间跨度, 并尝试了逻辑斯蒂回归、支持向量机、XGBoost 和 LightGBM 四种不同的模型。此外还使用 Kaggle 数据竞赛中常用的 Ensemble 方法, 对逻辑斯蒂回归、XGBoost 和 LightGBM 三个模型的预测概率分别赋予 0.05、0.7、0.25 的权重进行加权平均作为最终的预测结果。结果如表 3 所示:

如表 3 所示, XGBoost 展现出了最优的综合性能, 其在测试集上的 F1-Score 达到 0.5544, AUC 达到 0.7429, 表明模型具备较强的分类预测能力和泛化能力。

尽管 Ensemble 方法在评估指标上实现了微小的数值提升, 考虑到高频交易对低延迟的严苛要求, 集成模型带来的额外计算开销与其边际性能增益并不匹配。因此, 本研究后续环节将聚焦于 XGBoost 模型, 对其进行深入的统计评估与策略回测。

图 4 展示了 XGBoost 模型在三分类任务下的 ROC 曲线及其对应的 AUC 值。为了评估模型对不同市场状态的识别能力, 本次实验采用 One vs Rest 策略计算了每一类的 AUC 指标: 上涨类的  $AUC = 0.7598$ , 下跌类的  $AUC = 0.7508$ , 持平类的  $AUC = 0.7218$ 。由此说明模型在“涨”和“跌”这两个方向性类别上的预测性能优于“平”类别, 表明本研究构建的特征对于捕捉价格的方向性变动具有较高的敏感度, 而对于震荡或噪音行



表 3: 不同机器学习模型在训练集与测试集上的性能对比

| 模型                           | 数据集 | Accuracy      | Recall        | F1-Score      | AUC           |
|------------------------------|-----|---------------|---------------|---------------|---------------|
| Logistic Regression          | 训练集 | 0.5159        | 0.5184        | 0.5141        | N/A           |
|                              | 测试集 | 0.5246        | 0.5297        | 0.5249        | 0.7098        |
| Support Vector Machine (SVC) | 训练集 | 0.5138        | 0.5164        | 0.5117        | N/A           |
|                              | 测试集 | 0.5212        | 0.5273        | 0.5215        | 0.7110        |
| LightGBM                     | 训练集 | 0.5584        | 0.5597        | 0.5582        | N/A           |
|                              | 测试集 | 0.5561        | <b>0.5550</b> | 0.5543        | 0.7429        |
| XGBoost                      | 训练集 | 0.6320        | 0.6323        | 0.6321        | N/A           |
|                              | 测试集 | <b>0.5570</b> | 0.5543        | <b>0.5544</b> | <b>0.7441</b> |
| Ensemble                     | 测试集 | 0.5573        | 0.5551        | 0.5549        | 0.7442        |

注：加粗数值表示在测试集上该指标的最优表现（不考虑 Ensemble）。

情的解释力相对较弱。这一特性对于高频策略较为重要，因为捕捉趋势性机会往往比识别震荡更能贡献超额收益。

此外，整体平均  $AUC = 0.7429$  维持在较高水平，且各类别 ROC 曲线均未出现交叉或塌陷，说明模型在不同阈值设定下具有稳健的排序分类能力。

图 5 进一步展示了模型在测试集上的预测混淆矩阵。分析主对角线与非对角线元素的分布，矩阵的主对角线区域颜色最深，表明模型在大多数情况下能够正确划分“涨”、“跌”与“平”三种状态，分类准确性较高。在量化交易中，最严重的错误是将“涨”预测为“跌”或将“跌”预测为“涨”。观察矩阵右上角（真实跌/预测涨）和左下角（真实涨/预测跌）区域，其颜色极淡，数值分布极为稀疏。这表明模型具有较高的安全性，其错误主要集中在将“涨/跌”判断为“平”或将“平”预测为“涨/跌”，而较少出现严重的方向误判。

## 5 回测

在前述的模型评估中，基于 XGBoost 的机器学习模型展现了优异的预测分类性能。特别地，当基于  $H$  个时间步后的中间价计算预测分数与未来收益率的斯皮尔曼相关系数 RankIC 时，该指标高达 0.38。从统计学角度来看，这标志着极强的预测能力。

然而，中间价回测假设交易者能够以买卖价差的中点无摩擦成交，这在现实的高频交易中是难以做到的。为了验证策略的真实获利能力，本研究进行了更符合真实股票市场交易逻辑的回测。




图 4: XGBoost 模型的 ROC 曲线




图 5: XGBoost 模型的混淆矩阵

## 5.1 回测逻辑

不同于理想化的中间价回测，本研究的回测逻辑严格遵循 Taker 吃单交易机制，即买入挂单价建仓，卖出挂单价平仓。

设  $t$  时刻的买一价为  $P_{bid,t}$ ，卖一价为  $P_{ask,t}$ ，单边手续费率为  $c$ （本实验设为万分之二，即 2bps）。对于预测周期为  $H$  的交易信号，真实收益率  $R_{real}$  计算如下：

1. 做多交易：在  $t$  时刻以  $P_{ask,t}$  买入，在  $t+H$  时刻以  $P_{bid,t+H}$  卖出平仓：

$$R_{long,t} = \frac{P_{bid,t+H}}{P_{ask,t}} - 1 - 2c \quad (41)$$

2. 做空交易：在  $t$  时刻以  $P_{bid,t}$  卖出，在  $t+H$  时刻以  $P_{ask,t+H}$  买入平仓：

$$R_{short,t} = 1 - \frac{P_{ask,t+H}}{P_{bid,t}} - 2c \quad (42)$$

由此可见，每一笔交易不仅要覆盖双边手续费  $2c$ ，还必须克服买卖价差  $Spread = P_{ask} - P_{bid}$ 。这是导致高 RankIC 策略在实盘中亏损的根本原因。

## 5.2 5 折时间序列交叉验证

为了避免未来信息泄露并评估策略在不同市场环境下的稳健性，本研究采用了 5 折时间序列交叉验证。

该方法的具体流程如下：

1. 时间序列切分：将完整的时间序列数据按时间先后顺序划分为 5 个连续的片段。

2. 滚动窗口：

第 1 折：训练集  $[0, T]$ ，验证集  $[T, T+k]$

第 2 折：训练集  $[0, T+k]$ ，验证集  $[T+k, T+2k]$

...

第  $i$  折：训练集  $[0, T+(i-1)k]$ ，验证集  $[T+(i-1)k, T+ik]$

并且在每一折的训练集与验证集之间强制设置了 100 个时间步的时间间隔，该间隔超过预测范围  $H$ ，以防止未来信息泄露。

以上设置确保了模型在每一折的评估中，只能利用过去的信息来预测未来，完全模拟了真实的即时交易场景。

## 5.3 冷却机制

此外，为了防止在高频信号闪烁导致过度交易，我们在回测中引入了冷却机制：一旦开仓，策略在随后的  $N_{cool}$  个 Tick 内（本实验设为 10）将被强制锁定，不进行新的开仓操作。

## 5.4 回测结果

当引入上述真实的成交机制及万二手续费后，尽管模型具备高预测精度，基础策略在 5 折验证中仍表现出显著的亏损。这表明，虽然模型成功捕捉到了价格运动的方向，但其预测幅度尚不足以覆盖价差成本与交易手续费的损耗。

为了解决这一问题，我更改了回测时的投资策略，增加了开仓阈值的设定。其理论基础在于 XGBoost 预测分数的绝对值  $|S(x)|$  正比于模型对价格变动的置信度，据此不妨假设，只有当模型输出极端分数时，未来的价格变动才具有足够的动量突破价差阻力。此时的交易决策规则修正为：

$$Signal_t = \begin{cases} +1 & \text{if } P(Up|X_t) - P(Down|X_t) > \tau \\ -1 & \text{if } P(Up|X_t) - P(Down|X_t) < -\tau \\ 0 & \text{otherwise} \end{cases} \quad (43)$$

为了确定最优的开仓边界，在验证集上进行了阈值敏感性测试，遍历阈值  $\tau \in [0.7, 1.0]$ ，观察交易频率和总收益的变化关系。




图 6: 阈值敏感性测试

图 6展示了不同阈值下的策略表现：当阈值  $\tau < 0.8$  时，交易较为频繁，但总收益始终为负；当阈值  $\tau \in [0.8, 0.95]$  时，交易次数呈指数级下降，但总收益为正；当阈值  $\tau > 0.95$  时，交易次数接近于 0，总收益也趋于 0。

基于图 6，本研究最终选取  $\tau = 0.85$  作为实盘交易阈值。在此阈值下，交易策略虽然放弃了大量微小的波动机会，但确保了每一次开仓都具有较高的安全性，从而成功跨越了从统计预测到实际盈利的鸿沟。

5 折时间序列交叉验证的结果如表4所示，第 5 折的收益较低，可能是因为第 5 折的训练集包含了过多的历史信息，噪音过多导致模型的预测能力下降。

表 4:  $\tau = 0.85$  时的 5 折时间序列交叉验证结果

| Fold           | Accuracy     | Total Return | Win Rate     | Trade Count  |
|----------------|--------------|--------------|--------------|--------------|
| 1              | 0.546        | 0.024        | 48.4%        | 188          |
| 2              | 0.584        | 0.021        | 45.7%        | 197          |
| 3              | 0.578        | 0.056        | 45.7%        | 138          |
| 4              | 0.562        | 0.034        | 52.7%        | 203          |
| 5              | 0.548        | 0.008        | 42.0%        | 105          |
| <b>Average</b> | <b>0.564</b> | <b>0.029</b> | <b>46.9%</b> | <b>166.2</b> |

策略的平均胜率仅为 46.9%，低于 50% 的随机水平，但平均收益却为正值 0.029。这种低胜率、高盈亏比的特征，表明策略并非依赖频繁的微利交易累积收益，而是通过严格的过滤机制，捕捉那些能够产生足够大价格变动的爆发性机会，从而以单笔交易的高盈利覆盖了手续费损耗。




图 7: 累计收益

基于前述确定的最优阈值  $\tau = 0.85$ ，在未经任何分割的全体测试集上进行了最终的回测。图 7 展示了策略在考虑严格的买卖价差及双边交易成本后的净值演变曲线。

从图中可以观察到，资金曲线呈现出显著的向右上行趋势。在约为 600,000 个 Ticks 的测试周期内，策略累计收益率接近 20%，且最大回撤控制在较低水平，验证了模型在全市场周期下的鲁棒性。

此外，可以发现曲线呈现出阶梯状上升结构，而非平滑的线性增长。这与交易策略设定的高阈值逻辑高度一致，即在大部分时间内处于空仓等待状态，仅在模型预测置信度极高、且预期收益足以覆盖买卖价差和双边交易成本时才进行交易。这种间歇性的跃升模式证明了策略有效地避免了高频噪音交易的损耗。

该回测结果表明，本研究构建的 XGBoost 模型配合高阈值过滤机制，较好的克服

了高频交易中的成本损耗。它证明了模型所捕捉的特征不仅在统计上显著，在经济上也具备可观的获利能力。

## 6 结论

本研究基于 002507 股票的 Level-2 高频快照数据，构建了一套完整的从特征提取、机器学习模型训练到回测的短时高频价格预测框架。通过对 XGBoost、LightGBM 等模型在不同预测视野下的实证分析，得出以下主要结论：

第一，微观结构特征对短期价格变动具有显著的解释力。实验表明，基于订单流累加值、买卖方挂单量及价格相对 VWAP 位置等特征，能够有效捕捉市场供需的瞬时失衡。其中，XGBoost 模型在预测未来 15 秒 ( $H = 5$ ) 中间价变动方向的任务中表现最优，测试集 AUC 达到 0.7441。

第二，统计显著性与经济价值之间存在一定的鸿沟。研究发现，尽管模型在统计层面表现出较高的分类准确率，但在考虑了真实的 Taker 交易机制及双边万二的手续费后，基础策略因无法覆盖买卖价差和交易成本而出现亏损。这证实了在高频交易中，单纯追求高预测准确率并不等同于实际盈利能力。

第三，高阈值交易策略是解决上述问题的有效方法之一。通过引入高置信度阈值过滤机制 ( $\tau = 0.85$ )，策略在有效控制回撤的同时，实现了近 20% 的累计收益。该结果验证了只有当模型捕捉到剧烈的微观结构失衡信号时，价格变动的动量才足以覆盖交易成本。

综上所述，本研究不仅验证了机器学习在股票市场分析中的有效性，更强调了在算法交易策略开发中，结合微观流动性成本进行符合真实股票市场交易规则的回测的必要性。

源代码见 code.ipynb 文件。