

1 直方图估计

1.1 定义

一般情况下多维直方图估计的定义为

$$\hat{p}_H(y) = \begin{cases} \sum_{k=1}^m \frac{1}{v_k} \frac{\sum_{i=1}^n I_{T_k}(y_i)}{n} I_{T_k}(y), & \text{for } y \in D; \\ 0, & \text{otherwise.} \end{cases} \quad (1)$$

其中 D 是概率密度函数的有限支撑集, m 是区间的数量, T_k 表示第 k 个区间, v_k 表示第 k 个区间的体积 (在单变量中代表长度 h_k , 在二维中代表面积), n 表示总样本量, y_i 表示第 i 个观测样本。

令 $n_k = \sum_{i=1}^n I_{T_k}(y_i)$ 表示落入第 k 个区间中的样本数量, 则上述定义简化为:

$$\hat{p}_H(y) = \sum_{k=1}^m \frac{n_k}{nv_k} I_{T_k}(y) \quad (2)$$

一维情况下用 $t_{n,k+1} - t_{n,k}$ 表示第 k 个区间的长度:

$$\hat{p}_H(y) = \sum_{k=1}^m \frac{n_k}{n(t_{n,k+1} - t_{n,k})} I_{T_k}(y) \quad (3)$$

若固定区间长度为 h , 则上述定义进一步简化为:

$$\hat{p}_H(y) = \frac{n_k}{nh}, \quad \text{for } y \in T_k \quad (4)$$

1.2 直方图估计的均方误差

第 k 个区间中的点 y 的直方图估计的均方误差由下式给出:

$$\text{MSE}(\hat{p}_H(y)) = \frac{p_k(1-p_k)}{nv_k^2} + \left(\frac{p_k}{v_k} - p(y) \right)^2 \quad (5)$$

其由两部分组成, 分别为样本落在区间内 (服从二项分布) 的方差和密度估计与真实密度偏差的平方。

直方图估计的数学期望是 $E(\hat{p}_H(y)) = \frac{p_k}{v_k}$, 因此偏差项为 $\frac{p_k}{v_k} - p(y)$ 。若真实密度函数满足 Lipschitz 连续: $|p(y_1) - p(y_2)| \leq \gamma_k |y_1 - y_2|$, 则偏差项的上界为 $\gamma_k v_k$ 。

直方图估计的方差为

$$V(\hat{p}_H(y)) = V(n_k)/(nv_k^2) = p_k(1-p_k)/(nv_k^2) \quad (6)$$

其中 n_k 服从参数为 n 和 p_k 的二项分布. 利用积分中值定理, $V(\hat{p}_H(y)) \leq \frac{p(\xi_k)}{nv_k}$, 其中 ξ_k 第 k 个区间中的某一点。由此也能看出方差与偏差的权衡, 当区间宽度增加时, 偏差会增加但方差会减少。

由此, 均方误差放缩为下式:

$$\text{MSE}(\hat{p}_H(y)) \leq \frac{p(\xi_k)}{nv_k} + \gamma_k^2 v_k^2 \quad (7)$$

为最小化均方误差, 对区间宽度求导并令其为零, 解得:

$$h^*(k) = \left(\frac{p(\xi_k)}{2\gamma_k^2 n} \right)^{1/3} \quad (8)$$

这表明, 区间宽度应以 $\mathcal{O}(n^{-1/3})$ 的速度衰减, 此时均方误差量级为:

$$\text{MSE}^*(\hat{p}_H(y)) = \mathcal{O}(n^{-2/3}) \quad (9)$$

即直方图估计该点逼近真实密度函数的收敛速度为 $\mathcal{O}(n^{-1/3})$ 。

1.3 渐进均方积分误差 AMISE

上面计算的是在某一点的均方误差, 下面计算渐进均方积分误差 (AMISE) 评估全局误差。论文中考虑的是多维的情况。

假设所有矩形箱的各个维度边长恒定为 $h_1, \dots, h_d$, 且体积为 $v = \prod_{j=1}^d h_j$ 。

分别对方差和偏差进行积分, 并舍去高阶无关项, 得到渐进方差和渐进平方偏差:

$$\text{AIV}(\hat{p}_H) = \frac{1}{nv} = \frac{1}{n(h_1 \cdots h_d)} \quad (10)$$

$$\text{AISB}(\hat{p}_H) = \frac{1}{12} \sum_{j=1}^d h_j^2 R(\nabla_j p) \quad (11)$$

其中, $R(\nabla_j p)$ 表示真实密度函数在第 j 个维度上梯度的 “roughness”: $R(g) = \int_{\mathbb{R}^d} g(t)^2 dt$ 。

相加得到渐进均方积分误差:

$$\text{AMISE}(\hat{p}_H) = \frac{1}{n(h_1 \cdots h_d)} + \frac{1}{12} \sum_{j=1}^d h_j^2 R(\nabla_j p) \quad (12)$$

对 AMISE 公式关于 h_j 求导并令其为零:

$$h_{j*} = R(\nabla_j p)^{-1/2} \left(6 \prod_{i=1}^d R(\nabla_i p)^{1/2} \right)^{\frac{1}{2+d}} n^{-\frac{1}{2+d}} \quad (13)$$

此时渐进均方积分误差的衰减速率为:

$$\text{AMISE}^*(\hat{p}_H) = \mathcal{O} \left(n^{-\frac{2}{2+d}} \right) \quad (14)$$

但是, h_{j*} 的表达式中包含了真实密度函数的 $R(\nabla_j p)$, 它应该是未知的。

不妨假设真实分布是一个 “good general distribution”, 即协方差阵为对角矩阵 $\Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_d^2)$ 的 d 维正态分布, 此时 $R(\nabla_j p) = \frac{1}{2^{d+1} \pi^{d/2} \sigma_j^2 |\Sigma|^{1/2}}$ 。

一维情况下, $R(p') = 1/(4\sqrt{\pi}\sigma^3)$, 代入即得 $h^* = 3.49\sigma n^{-1/3}$ 。在实际计算中, 可以使用样本标准差 s 来代替总体标准差 σ 。

相比设定直方图区间的宽度, 直接设定直方图区间的数量往往更多的被使用。假设直方图的区间数服从一个对称的二项分布模型, 有:

$$n = \sum_{k=0}^{m-1} \binom{m-1}{k} = 2^{m-1}. \quad (15)$$

可以取区间的数量 $m = 1 + \log_2 n$ 。

2 核密度估计

2.1 Rosenblatt 直方图估计与核密度估计

一维情况下, 上面的直方图估计区间位置是固定的, Rosenblatt 直方图估计则以目标点 y 为中心, 向两侧各延伸 $h/2$ 的距离构建一个动态区间, 统计落入该区间 $(y - h/2, y + h/2]$ 内的样本点数量:

$$\hat{p}_R(y) = \frac{\#\{y_i : y_i \in (y - h/2, y + h/2]\}}{nh} \quad (16)$$

其可以等价地表示为经验分布函数的形式:

$$\hat{p}_R(y) = \frac{P_n(y + h/2) - P_n(y - h/2)}{h} \quad (17)$$

若改写为针对每个样本点 y_i 的求和形式:

$$\hat{p}_R(y) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{y - y_i}{h}\right) \quad (18)$$

其中, 这里函数 $K_1(x)$ 的定义为: 当 $|x| < 1/2$ 时, $K_1(x) = 1$; 否则 $K_1(x) = 0$ 。 $K(x)$ 也可以取其它的核函数, 这便是核密度估计的一般形式。

例如:

$$\begin{aligned} K_2(x) &= (1 - |x|)I_{[-1,1]}(x) \quad (\text{三角形核}) \\ K_3(x) &= \frac{3}{4}(1 - x^2)I_{[-1,1]}(x) \quad (\text{二次曲线核}) \\ K_4(x) &= \frac{15}{16}(1 - x^2)^2I_{[-1,1]}(x) \quad (\text{双二次核}) \\ K_5(x) &= \frac{70}{81}(1 - |x|^3)^3I_{[-1,1]}(x) \quad (\text{双三次核}) \\ K_6(x) &= \frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}} \quad (\text{高斯核}) \end{aligned}$$

一般地, 核函数应该满足如下要求:

1. $K(x) \geq 0$;
2. $\int_{-\infty}^{\infty} K(x)dx = 1$;
3. $K(x)$ 是偶函数;
4. $\int_{-\infty}^{\infty} x^2 K(x)dx < +\infty$ 。

可以利用这些性质来推导核密度估计的偏差和方差。

2.2 核密度估计的理论性质

在 Emanuel Parzen 1962 年发表的论文 On Estimation of a Probability Density Function and Mode 中, 作者详细推导了核密度估计的理论性质。

2.2.1 渐进无偏性

当 $h(n)$ 满足 $h(n) > 0$ 且 $\lim_{n \rightarrow \infty} h(n) = 0$, 且核函数 $K(y)$ 绝对有界且可积 $\sup |K(y)| < \infty$, $\int |K(y)|dy < \infty$, 以及 $\lim_{y \rightarrow \infty} |yK(y)| = 0$ 时, 有:

$$E[f_n(x)] = \int_{-\infty}^{\infty} \frac{1}{h(n)} K\left(\frac{x - y}{h(n)}\right) f(y) dy \quad (19)$$

对于真实密度函数 $f(x)$ 的任意连续点 x , 均有:

$$\lim_{n \rightarrow \infty} E[f_n(x)] = f(x) \quad (20)$$

这说明了以上条件下核密度估计是真实密度函数的渐近无偏估计。

2.2.2 均方一致性

估计量的均方误差可分解为方差与偏差的平方和:

$$E[f_n(x) - f(x)]^2 = \text{Var}[f_n(x)] + b^2[f_n(x)] \quad (21)$$

论文给出了方差的极限:

$$\lim_{n \rightarrow \infty} nh(n) \text{Var}[f_n(x)] = f(x) \int_{-\infty}^{\infty} K^2(y) dy \quad (22)$$

由于渐近无偏性已经保证了偏差 $b[f_n(x)] \rightarrow 0$, 如果 $h(n)$ 满足条件:

$$\lim_{n \rightarrow \infty} nh(n) = \infty \quad (23)$$

有 $\lim_{n \rightarrow \infty} E|f_n(x) - f(x)|^2 = 0$, 即核密度估计在均方意义下是一致收敛的。

2.2.3 渐进正态性

由于核密度估计 $f_n(x)$ 可以看作是 n 个独立同分布随机变量 $V_{nj} = \frac{1}{h(n)} K\left(\frac{x-X_j}{h(n)}\right)$ 的样本均值, 可以验证 Lyapunov 条件来应用中心极限定理。

论文指出, 对于任意 $\delta > 0$, 只要 $\int |K(y)|^{2+\delta} dy < \infty$, 就可以证明高阶矩满足趋于 0 的条件。因此, 经过标准化处理后的核密度估计量依分布收敛于标准正态分布:

$$\lim_{n \rightarrow \infty} P\left[\frac{f_n(x) - E[f_n(x)]}{\sigma[f_n(x)]} \leq c\right] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^c e^{-\frac{y^2}{2}} dy = \Phi(c) \quad (24)$$

2.3 核密度估计的收敛速度

利用傅里叶变换, 核密度估计 $f_n(x)$ 的期望 $E[f_n(x)]$ 与偏差 $b[f_n(x)]$ 可以表示为:

$$E[f_n(x)] = (2\pi)^{-1} \int_{-\infty}^{\infty} e^{-iux} k(hu) \varphi(u) du \quad (25)$$

$$b[f_n(x)] = (2\pi)^{-1} \int_{-\infty}^{\infty} e^{-iux} \{k(hu) - 1\} \varphi(u) du \quad (26)$$

其中 $k(u)$ 是核函数的傅里叶变换, $\varphi(u)$ 是真实分布的特征函数。

若存在一个正数 r , 使得以下极限存在且为一个有限的非零常数 k_r :

$$k_r = \lim_{u \rightarrow 0} \frac{1 - k(u)}{|u|^r} \quad (27)$$

称 r 为变换 $k(u)$ 的特征指数, k_r 为特征系数。

当 $h \rightarrow 0$ 时, 偏差满足如下关系:

$$\frac{b[f_n(x)]}{h^r} \rightarrow k_r f^{(r)}(x) \quad (28)$$

其中 $f^{(r)}(x) = -(2\pi)^{-1} \int_{-\infty}^{\infty} e^{-iux} |u|^r \varphi(u) du$ 。

均方误差由方差与偏差的平方和构成, 可写为:

$$E|f_n(x) - f(x)|^2 \sim \frac{f(x)}{nh} \int_{-\infty}^{\infty} K^2(y) dy + h^{2r} |k_r f^{(r)}(x)|^2 \quad (29)$$

为了找到使上述均方误差最小的窗宽 h , 给出关于代数式极值的引理: 对于给定的正数 A, B, α, β , 有:

$$\min_{x>0} Ax^\alpha + Bx^{-\beta} = (\alpha + \beta) \{(A/\beta)^\beta (B/\alpha)^\alpha\}^{\frac{1}{\alpha+\beta}} \quad (30)$$

最小值在 $x_{\min} = (\beta B/\alpha A)^{\frac{1}{\alpha+\beta}}$ 处取得。

令 $x = h, \alpha = 2r, \beta = 1$, 解得:

$$h^* = \left\{ \frac{f(x) \int_{-\infty}^{\infty} K^2(y) dy}{n 2r |k_r f^{(r)}(x)|^2} \right\}^{\frac{1}{2r+1}}$$

将窗宽 h^* 代回均方误差公式中, 得到均方误差为:

$$E|f_n(x) - f(x)|^2 \sim (2r+1) \left\{ \frac{f(x)}{n^{2r}} \int_{-\infty}^{\infty} K^2(y) dy \right\}^{\frac{2r}{1+2r}} |k_r f^{(r)}(x)|^{\frac{2}{1+2r}} \quad (31)$$

由上式可知, 均方误差趋向于 0 的速率与 $n^{-\frac{2r}{1+2r}}$ 成正比。

在常见的非参数估计下, 取核函数的特征指数 $r = 2$, 得到核密度估计 $f_n(x)$ 的均方误差收敛速度为 $\mathcal{O}(n^{-4/5})$ 。根据 Farrell (1972) 的 Minimax 理论, 它无法达到参数估计的根号 n 速率。

3 最优收敛速度

在 Farrell 1972 年的论文 On the Best Obtainable Asymptotic Rates of Convergence in Estimation of a Density Function at a Point 中, 作者定义了 m 维空间上的函数 f 被认为属于 $C_{k\alpha}$ 函数族, 当且仅当它满足以下三个条件:

- f 及其前 $k-1$ 阶导数都是连续的。
- f 的 $k-1$ 阶偏导数相对于 f 的所有 m 个可能的 k 阶偏导数是绝对连续的。
- 其 k 阶偏导数在空间中几乎处处存在, 且受到常数 α 的约束:

$$\left| \frac{\partial^k f}{\partial x_1^{k_1} \cdots \partial x_m^{k_m}} \right| \leq \alpha, \quad \text{其中 } k_1 + \cdots + k_m = k \quad (32)$$

当维度 $m = 1$ 且 $k \geq 1$ 时, 可以构造出一个估计量序列 $\{\gamma_n, n \geq 1\}$, 在 $C_{k\alpha}$ 空间内满足:

$$\lim_{a \rightarrow \infty} \lim_{n \rightarrow \infty} \inf_{f \in C_{k\alpha}} P_f \left(|\gamma_n(X_1, \dots, X_n) - f(0)| \leq an^{-\frac{k}{2k+1}} \right) = 1 \quad (33)$$

该公式表明, 在一维情况下, 估计量的绝对误差最优收敛速度 (相当于均方根误差的收敛速度) 被锁定在了 $\mathcal{O}(n^{-\frac{k}{2k+1}})$ 。

进一步地, 当 $m \geq 1$ 时, 对于定义在 m 维空间上的 $C_{k\alpha}$ 函数族, 非参数估计量能达到的绝对误差最优收敛速度被限制为:

$$\mathcal{O}\left(n^{-\frac{k}{2k+m}}\right) \quad (34)$$

4 窗宽选择方法

如前文所述, 我们需要最小化渐近均方积分误差 (AMISE)。除了前文提到的假设真实分布为正态分布外, 可以使用交叉验证的方法来选择窗宽。

AMISE 公式包含真实密度函数的 “roughness”, 例如直方图估计中的 $R(p')$ 或核密度估计中的 $R(p'')$ 。

以直方图为例, 可以通过有限差分 $\hat{p}'(t_k)$ 的黎曼近似来估算积分 $R(p')$:

$$\hat{R}(p') = h \sum (\hat{p}'(t_k))^2 = \frac{1}{n^2 h^3} \sum (n_{k+1} - n_k)^2 \quad (35)$$

其中, $\hat{p}'(t_k)$ 是第 k 个和第 $k+1$ 个区间中点处的有限差分, 即

$$\hat{p}'(t_k) = \frac{n_{k+1}/(nh) - n_k/(nh)}{h} \quad (36)$$

这一估计是有偏的, 其数学期望展开式为:

$$E(\hat{R}(p')) = R(p') + \frac{2}{nh^3} + \dots \quad (37)$$

对上述偏差进行校正, 即减去 $2/(nh^3)$ 这一偏差项, 然后将校正后的值代回 AMISE 的公式中。在得到 AMISE 表达式后, 针对一系列不同的窗宽 h 值计算其对应的 AMISE 估计值, 最终选择使该估计值达到最小的 h 。这一方法被称作 “biased cross validation”。

这一方法不仅适用于直方图估计, 也同样适用于核密度估计, 但计算过程会变得更加复杂。

交叉验证方法存在一定的局限性。Terrell (1990) 的研究指出, 由于该方法存在过大的 sampling variability, 在数据波动较大时, 交叉验证给出的窗宽 h 可能不够稳定。

5 模拟实验

为了验证收敛速度确实为 $\mathcal{O}(n^{-4/5})$, 利用蒙特卡洛模拟方法进行模拟实验。

实验选取标准正态分布 $f(x) \sim \mathcal{N}(0, 1)$ 作为已知的真实概率密度函数。为了在计算机中近似计算积分, 在区间 $[-5, 5]$ 上划分了等距的离散网格点, 步长记为 Δx 。

实验设定了一系列样本量 $n \in \{50, 100, 200, \dots, 6400\}$ 。对于每一个特定的样本量 n , 重复进行 $M = 100$ 次独立抽样实验。

在每一次独立实验中, 从标准正态分布中随机生成大小为 n 的样本, 并调用高斯核密度估计函数对样本进行拟合。在调用的核密度估计库中, 算法默认采用的窗宽 h 已经满足 $h \propto n^{-1/5}$ 的衰减速率。

利用黎曼和近似计算实验的积分平方误差 ISE:

$$\text{ISE} = \int_{-\infty}^{\infty} (\hat{f}_n(x) - f(x))^2 dx \approx \sum_i (\hat{f}_n(x_i) - f(x_i))^2 \Delta x \quad (38)$$

将 M 次实验得到的 ISE 取平均, 即可得到该样本量 n 下均方积分误差的蒙特卡洛估计值:

$$\text{MISE}(n) \approx \frac{1}{M} \sum_{m=1}^M \text{ISE} \quad (39)$$

KDE 的均方积分误差应满足 $\text{MISE}(n) = C \cdot n^{-0.8}$ 。对等式两边同时取对数, 可得:

$$\log(\text{MISE}) = -0.8 \log(n) + \log(C) \quad (40)$$

这表明, 在双对数坐标系下, 样本量 n 与 MISE 之间应当呈现为线性关系, 且斜率等于 -0.8 。实验结果表明, 输出的斜率为 -0.73 , 较为接近理论值 -0.8 。




图 1: 样本量 n 与 MISE 的双对数图

实验代码如下:

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import norm, gaussian_kde
from scipy.stats import linregress
np.random.seed(42)

samples = np.array([50, 100, 200, 400, 800, 1600, 3200, 6400]) # 样本量
trials = 100 # 模拟次数

grid = np.linspace(-5, 5, 1000)
dx = grid[1] - grid[0]
density = norm.pdf(grid) # 真实密度函数  $N(0,1)$ 

mises = []
for n in samples:
    ises = []
    for _ in range(trials):
        data = np.random.normal(0, 1, n)
        kde = gaussian_kde(data)
        estimated = kde.evaluate(grid) # 核密度估计
        ise = np.sum((estimated - density)**2) * dx
        ises.append(ise)
    mise = np.mean(ises) # 估算均方误差
    mises.append(mise)

log_n = np.log10(samples)
log_mise = np.log10(mises)
slope, intercept, r_value, p_value, std_err = linregress(log_n, log_mise)
print(f"斜率: {slope:.3f}")
fig = plt.figure(figsize=(8, 6))
plt.plot(log_n, log_mise, 'bo-', label=f'MISE (slope={slope:.3f})')
log_08 = -0.8 * log_n + intercept + (slope - (-0.8)) * log_n[0]
plt.plot(log_n, log_08, 'r--', label='$O(n^{-0.8})$')
plt.xlabel('$\log n$')
plt.ylabel('$\log \mathrm{MISE}$')
plt.legend()
plt.grid(True)
fig.savefig('plot.png')
plt.show()
```