

Homework 4

张子乐,3230104237

2026-04-09

1. 作业题目

设独立的观测样本 Y_j 服从参数为 K 和 η 的贝塔—二项分布。根据贝叶斯统计的做法，假设参数 (K, η) 也是随机变量且服从如下的“无信息”先验分布密度：

$$\pi(K, \eta) \propto \frac{1}{(1+K)^2} \frac{1}{\eta(1-\eta)},$$

要求计算 $E(\log K|Y)$ 的值。

2. 算法设计

由于后验密度难以直接抽样，使用标准化的重要抽样法，分以下步骤进行：

1. 为了消除未知参数 $K > 0$ 和 $0 < \eta < 1$ 的取值限制，作变换 $\alpha = \log K$ 和 $\beta = \log \frac{\eta}{1-\eta}$ ，则 $\alpha, \beta \in (-\infty, \infty)$ 。 α, β 对应的后验密度为：

$$p(\alpha, \beta|Y) \propto \frac{e^\alpha}{(1+e^\alpha)^2} \prod_{j=1}^n \frac{B\left(\frac{e^\alpha}{1+e^{-\beta}} + y_j, \frac{e^\alpha}{1+e^\beta} + n_j - y_j\right)}{B\left(\frac{e^\alpha}{1+e^{-\beta}}, \frac{e^\alpha}{1+e^\beta}\right)}.$$

2. 选用 $t(4)$ 分布作为试抽样分布，生成试抽样样本 (α_i, β_i) 。
3. 据此估计 $E(\log K|Y)$ 为：

$$\hat{\alpha} = \frac{\sum_{i=1}^N \alpha_i \frac{p(\alpha_i, \beta_i|Y)}{g(\alpha_i)g(\beta_i)}}{\sum_{i=1}^N \frac{p(\alpha_i, \beta_i|Y)}{g(\alpha_i)g(\beta_i)}}.$$

3. 样本生成的 R 函数实现

3.1 beta-binomial 分布的概率质量函数

先定义 beta-binomial 分布的概率质量函数。其中 n 是正整数， y 是非负整数且 $0 \leq y \leq n$ 。

```
dbetabin <- function(y, n, K, eta)
{
  choose(n, y)*beta(K*eta + y, K*(1-eta) + n-y)/beta(K*eta, K*(1-eta))
}
```

3.2 以 α , β 为自变量的后验密度函数

定义以 α , β 为自变量的后验密度函数（差一个未知的常数倍）。书上给出的原代码将浮点数连续相乘可能导致数值下溢，因此改用对数形式计算。

```
# 书上的原代码，n 取 20 时能正常使用，但 n 取 30 时估计值就已经是 NaN 了。
# p.post <- function(a, b)
# {
#   K <- exp(a)
#   eta <- 1/(1 + exp(-b))
#   val <- K / (1+K)^2
#   beta0 <- beta(K*eta, K*(1-eta))
#   for(j in seq(n)){
#     val <- val * beta(K*eta + yarr[j], K*(1-eta) + narr[j] - yarr[j]) / beta0
#   }
#   val[beta0==0] <- 0
#   val
# }
```

```
# 对数形式的代码
log.p.post <- function(a, b)
{
  K <- exp(a)
  eta <- 1 / (1 + exp(-b))
  log_val <- log(K) - 2 * log(1 + K)
  log_beta0 <- lbeta(K * eta, K * (1 - eta))
  # 对数尺度上，累乘变为累加
  for(j in seq(n)){
    log_val <- log_val + lbeta(K * eta + yarr[j], K * (1 - eta) + narr[j] - yarr[j]) - log_beta0
  }
  return(log_val)
}
```

3.3 生成观测样本

用模拟方法生成观测样本，先生成小批量的样本 ($n = 20$)。

```
set.seed(6)
K.true <- 10
eta.true <- 0.5
narr <- sample(20:50, size=20, replace=TRUE)
n <- length(narr)
yarr <- numeric(n)
for(j in seq(n))
{
  parr <- dbetabin(seq(0, narr[j]), narr[j], K.true, eta.true)
  yarr[j] <- sample(seq(0, narr[j]), size=1, prob=parr, replace=TRUE)
}
rbind(narr, yarr)
```

4. 重要抽样法的 R 函数实现

4.1 抽样与估计

下面用标准化的重要抽样法估计 $E(\log K|Y) = E(\alpha|Y)$ 。取 α 和 β 的试抽样分布为 $t(4)$ 。为了保持数值的稳定性，权重的计算在对数尺度下进行。

```
set.seed(6)
N <- 10000
df.t <- 4
alpha.samp <- rt(N, df.t)
beta.samp <- rt(N, df.t)
# 在对数尺度上计算
log_wei <- numeric(N)
for (i in seq_len(N)) {
  # log(权重) = log(后验) - log(提议分布)
  log_wei[i] <- log.p.post(alpha.samp[i], beta.samp[i])
    - dt(alpha.samp[i], df.t, log=TRUE)
    - dt(beta.samp[i], df.t, log=TRUE)
}
wei1 <- exp(log_wei - max(log_wei))
wei <- wei1 / sum(wei1) # 归一化
est <- sum(alpha.samp*wei) / sum(wei) # 重要抽样法的估计值
```

```
cat(" 重要抽样法的估计值: ", round(est, 4), "\n")
重要抽样法的估计值: 1.6091
cat("log K 的真实值: ", round(log(K.true), 4), "\n")
log K 的真实值: 2.3026
```

估计结果：用 10000 个抽样的重要抽样法给出的 $\log K$ 的后验估计值为 1.6091， $\log K$ 的真实值为 2.3026。可以发现重要抽样法的估计值与真实值有一定差距，可能是因为仅生成了 20 组观测数据（`narr` 和 `yarr`），观测样本量过小。


4.2 诊断

下面给出归一化权重的分布情况。重要性权重最好取值比较均匀，否则重要性权重很小的抽样点基本不起作用，效率较低。

```
wei <- wei / sum(wei) * N
summary(wei)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.00000	0.00000	0.00000	1.00000	0.00116	69.14682

```
boxplot(wei) # 重要性权重的箱线图。可以看出绝大多数点权重较小。
```



下面定义有效样本量 (Effective Sample Size, ESS) 来衡量重要抽样的效率。

$$ESS = \frac{(\sum_{i=1}^n w_i)^2}{\sum_{i=1}^n w_i^2}$$

标准重要抽样法的有效样本量远小于抽样总数 10000，效率较低。

```
# 计算有效样本量
ESS <- function(w)
{
  return (sum(w)^2 / sum(w^2))
}
```

```
cat(" 标准重要抽样法的有效样本量: ", round(ESS(wei), 2), "\n")
标准重要抽样法的有效样本量:  305.98
```

5. 带舍选控制的重要抽样法的 R 函数实现

舍选控制是解决“绝大多数抽样点都贡献很小”问题的一种技术。根据权重的分位点，取舍选控制阈值 c 为 90% 分位数。对 N 个权重，超过阈值的都保留；小于阈值的，以概率 W_i/c 保留， c 是阈值，其它的丢弃，这样减少了样本量。

```
quantile(wei, c(0.5, 0.75, 0.8, 0.85, 0.9, 0.95, 0.99)) # 权重的分位数
          50%          75%          80%          85%          90%          95%
1.591834e-07 1.159874e-03 6.430473e-03 3.335993e-02 2.533905e-01 2.815033e+00
          99%
3.541120e+01
```


```
wei.cut <- unname(quantile(wei, 0.90)) # 取舍选控制阈值  $c$  为 90% 位数
```

```
sele <- wei < wei.cut
n.sele <- sum(sele)
i.over <- seq(N)[!sele] # 超过阈值的下标，保留
i.under <- seq(N)[sele] # 低于阈值的下标，按概率保留
i.accept <- i.under[runif(n.sele) < wei[sele] / wei.cut] # 选出按概率保留部分
i.keep <- c(i.over, i.accept)
N1 <- length(i.keep) # 保留的样本量
N1
[1] 1231
```

原来的 10000 个抽样仅保留了 1000 多个。打印出新权重的分布情况并绘制箱线图，可以明显发现较小的权重被截断了。而有效样本量并没有发生明显的变化，说明舍弃的较小权重对估计的贡献较小。

```
wei.new <- pmax(wei[i.keep], wei.cut) # 舍选控制后权重的分布情况
summary(wei.new)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
0.2534  0.3644  1.5313  8.1210  7.5875 69.1468
```

```
boxplot(wei.new) # 新权重的箱线图
```



```
cat(" 舍选控制后有效样本量: ", round(ESS(wei.new), 2), "\n")
舍选控制后有效样本量: 305.79
```

```
est.new <- sum(alpha.samp[i.keep]*wei.new)/sum(wei.new) # 新的估计值
cat(" 带舍选控制的重要抽样法的估计值: ", round(est.new, 4), "\n")
带舍选控制的重要抽样法的估计值: 1.6093
```

小结：标准的重要抽样法和带舍选控制的重要抽样法的估计较为接近，说明算法并未出错。下面尝试增加观测样本量到 500，重新生成数据并进行重要抽样估计。

6. 增大观测样本量后的重要抽样估计

代码与之前一致，只是将观测样本量从 20 增加到 500，并将抽样次数增加到 50000。此时的估计值与真实值更加接近了，但权重分布并不均匀，且权重都非常小，有效样本量也骤降。

```

narr <- sample(20:50, size = 500, replace = TRUE)
n <- length(narr)
yarr <- numeric(n)
for(j in seq(n)) {
  parr <- dbetabin(seq(0, narr[j]), narr[j], K.true, eta.true)
  yarr[j] <- sample(seq(0, narr[j]), size=1, prob=parr, replace=TRUE)
}
N <- 50000
alpha.samp <- rt(N, df.t)
beta.samp <- rt(N, df.t)
log_wei <- numeric(N)
for (i in seq_len(N)) {
  log_wei[i] <- log.p.post(alpha.samp[i], beta.samp[i]) -
    dt(alpha.samp[i], df.t, log=TRUE) -
    dt(beta.samp[i], df.t, log=TRUE)
}
wei2 <- exp(log_wei - max(log_wei))
wei.more <- wei2 / sum(wei2)
est.more <- sum(alpha.samp * wei.more) # 增大观测样本量后的估计值

```

```


cat(" 增大观测样本量后的估计值: ", round(est.more, 4), "\n")
增大观测样本量后的估计值:  2.3975

```

```

summary(wei.more) # 权重的分布情况
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
0.00000 0.00000 0.00000 0.00002 0.00000 0.06890
boxplot(wei.more) # 权重的箱线图

```



```
cat(" 增大观测样本量后的有效样本量: ", round(ESS(wei.more), 2), "\n")
增大观测样本量后的有效样本量: 25.72
```

总结:

t(4) 分布大多数抽样点都会落在 0 附近，而 α 的真实值在 2.3 附近，导致几乎所有的点权重都较小。增大观测样本量后，权重的最大值为 0.0689043，99% 分位数为 1.515337×10^{-18} ，即使采用舍选控制进行截断，大多数权重仍然会很小。AI 给出的建议为将 `alpha.samp` 平移到真实值附近进行抽样，这与 Laplace Approximation 有异曲同工之妙。

7. Laplace-IS 的 R 函数实现

Laplace-IS 的核心思想是取 $g(b) = \mathcal{N}(\hat{b}, H^{-1})$ 为建议分布，其中 $\hat{b}$ 是后验密度的极大值点， H 是后验密度在 $\hat{b}$ 处的 Hessian 矩阵。

7.1 计算极大值点 $\hat{b}$ 和 Hessian 矩阵 H

```
# 辅助函数
neg.log.p.post <- function(par) {
  -log.p.post(par[1], par[2])
}
opt <- optim(par = c(0, 0), fn = neg.log.p.post, hessian = TRUE) # 寻找极大值点
```

```

mode <- opt$par
hessian <- opt$hessian # Hessian 矩阵
cov <- solve(hessian) # Hessian 矩阵的逆
cat(" 找到的极值点:", round(mode, 4), "\n")
找到的极值点: 2.389 0.0341

```

7.2 Laplace-IS 的抽样与估计

```

set.seed(6)
N <- 10000
samp_laplace <- rmvnorm(N, mean = mode, sigma = cov) # 构造建议分布
alpha.samp.lap <- samp_laplace[, 1] # 从建议分布中共抽样
beta.samp.lap <- samp_laplace[, 2]
log_wei_lap <- numeric(N) # log-weights
for (i in seq_len(N)) {
  log_wei_lap[i] <- log.p.post(alpha.samp.lap[i], beta.samp.lap[i]) -
    dmnorm(samp_laplace[i, , drop=FALSE], mean = mode, sigma = cov, log = TRUE)
}
wei1_lap <- exp(log_wei_lap - max(log_wei_lap))
wei.lap <- wei1_lap / sum(wei1_lap) # 归一化
est.lap <- sum(alpha.samp.lap * wei.lap) # Laplace-IS 的估计值

cat("Laplace-IS 的估计值: ", round(est.lap, 4), "\n")
Laplace-IS 的估计值: 2.3864


```

7.3 Laplace-IS 的诊断

```

summary(wei.lap) # 权重的分布情况
      Min.   1st Qu.   Median     Mean   3rd Qu.    Max.
5.056e-05 9.797e-05 9.990e-05 1.000e-04 1.020e-04 1.791e-04
boxplot(wei.lap) # 权重的箱线图

```



```
cat("Laplace-IS 的有效样本量: ", round(ESS(wei.lap), 2), "\n")  
Laplace-IS 的有效样本量: 9971
```

总结:

- 1. 通过 Laplace-IS 的方法, 估计值为 2.3864, 与真实值 2.3026 更加接近。
- 2. 权重的分布更加均匀, 有效样本量也大幅提升, 说明 Laplace-IS 有效提升了重要抽样的效率。